

オープンネットワークOS SONICへの取り組み

日本電信電話株式会社

NTTネットワークイノベーションセンタ

中野 寬二、杉園 幸司

目次



- SONICの概要
- SONiCの課題
- SONiCのマネジメントプレーン(外部制御プロトコル)
- SONiCのコントロールプレーン(ECMP経路処理)
- SONiCのデータプレーン(伝送機能サポート)

目次



- SONiCの概要
- SONICの課題
- SONiCのマネジメントプレーン(外部制御プロトコル)
- SONiCのコントロールプレーン(ECMP経路処理)
- SONiCのデータプレーン(伝送機能サポート)

ホワイトボックススイッチについて



- ホワイトボックススイッチによるハードウェアとソフトウェアのデカップリングが進んできた。
- 日本国内のホワイトボックス市場は2021年から2026年の年平均成長率は5.2%と言われている.
- このホワイトボックススイッチ上で動作するオープンなネットワークOSはMicrosoftが開発を開始した SONiCがデファクトになりつつある.

Switch (Closed NOS + **Closed Hardware**)

HW/SW(NOS)一体型

NOS Whitebox Hardware

HW/SW(NOS)の分離

SONICについて



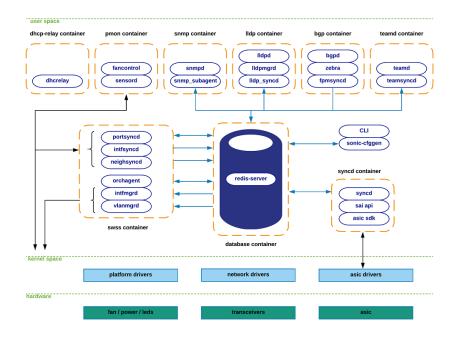
- SONiCはオープンなネットワークOSである。
- MicrosoftがOCP(Open Compute Project)に2016年に寄贈し、 2022まではOCP Networking傘下、2022以降はLinux Foundationで管理されている。
- 国内の導入企業としてKDDI、LINEヤフーがある。

https://www.zdnet.com/article/microsoft-submits-new-open-sourced-networking-components-to-open-compute-project/ https://www.linuxfoundation.org/press/press-release/software-for-open-networking-in-the-cloud-sonic-moves-to-the-linux-foundation https://www.janog.gr.jp/meeting/janog51/sonic/ https://www.janog.gr.jp/meeting/janog52/sonicztp/

SONiCの技術概要



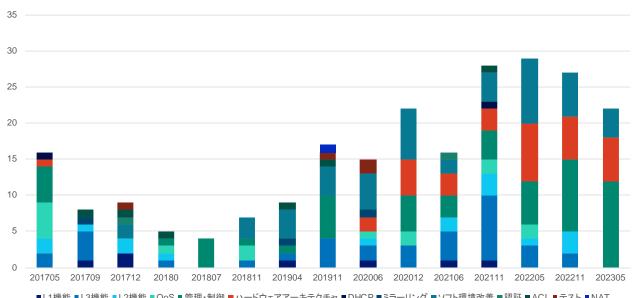
- コンテナベースアーキテクチャ
 - Docker (標準)
 - Kubernetes
- Redis DB集中管理システム
- Pub/Subメッセージング(Redis)
- SAIを用いたスイッチASIC制御



SONiCの動向



SONiCは基本的にDCユースケース向けに開発が進み、機能数は最初のリリー スを除くと2022年までは増加傾向だったがピークアウトしている傾向



■L1機能 ■L3機能 ■L2機能 ■QoS ■管理・制御 ■ハードウェアアーキテクチャ ■DHCP ■ミラーリング ■ソフト環境改善 ■認証 ■ACL ■テスト ■NAT

目次



- SONiCの概要
- SONiCの課題
- SONiCのマネジメントプレーン(外部制御プロトコル)
- SONiCのコントロールプレーン(ECMP経路処理)
- SONiCのデータプレーン(伝送機能サポート)

SONiCにおける現状見えている課題と検討したアプローチ



プレーン	分類	コミュニティSONiCの状況/課題	検討したアプローチ
	設定変更コマンド体系	コマンド数が少ない。 L2/L3設定コマンド体系が異なる	KLISH CLI拡張 (Management Framework)
マネジメント	外部制御プロトコル	設定項目が限定的	YANG拡張 (Management Framework)
	外部制御プロトコル	REST, gNMIのみ。旧来から利用するNETCONF に対応不可。相互接続性に難あり。	NETCONF拡張 (Management Framework)
-> -	ルーティングプロトコル	標準ではBGPのみ利用可。OSPF等のIGPサポート 不可。	COPP関連の設定ファイル変更
コントロール	ECMP経路処理	旧来の経路追加メッセージのみ利用可。Nexthop Group (netlinkメッセージ)が利用不可。	Fpmsyncd機能*拡張 *fpm形式のnetlinkメッセージの経路更新メッ セージをRedis DBに同期する機能
	伝送機能のサポート	• Alibabaによる伝送機能のサポートの議論しているが対応ハードウェアの入手性に難あり。	・ 市中製品による伝送機能の実装
データ	SAIのサポート	 SAIサポートの対応状況がASIC毎に異なる。 BroadcomはSAIフルスペックをサポート不可 	 SAIの多くのAPIに準拠していた Intel Tofinoが開発中止。機能拡 張には他チップ検討要 Broadcomはコミュニティ版 libsaiに意図的に制限があるため メーカとの連携検討要

目次

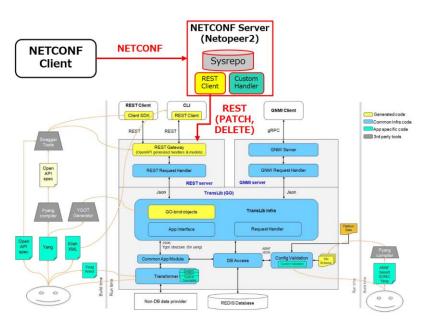


- SONICの概要
- SONICの課題
- · SONiCのマネジメントプレーン(外部制御プロトコル)
- SONiCのコントロールプレーン(ECMP経路処理)
- SONiCのデータプレーン(伝送機能サポート)

NETCONF機能の概要



- SONiCのNBIにはREST、gNMIのみ対応しておりNW装置に多く活用されているNETCONFには対応 していない。そのためNETCONFに対応することで相互接続性の向上を行う。
- NETCONFクライアントからSONiCの設定投入・設定削除・設定取得等が問題なく動作の確認をした。



対応し	.7	いろ	桦能
~ 1 // L/ \	\sim	0.7	1/32 HC

RFC Operation Name	Supported
edit-config	Partially
get-config	Partially
get	No
copy-config	No
delete-config	No
lock	Yes
unlock	Yes
close-session	Yes
kill-session	Yes

目次

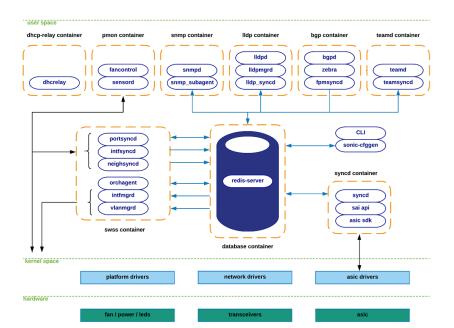


- SONICの概要
- SONICの課題
- SONiCのマネジメントプレーン(外部制御プロトコル)
- SONiCのコントロールプレーン(ECMP経路処理)
- SONiCのデータプレーン(伝送機能サポート)

SONiCのルーティング機能の課題



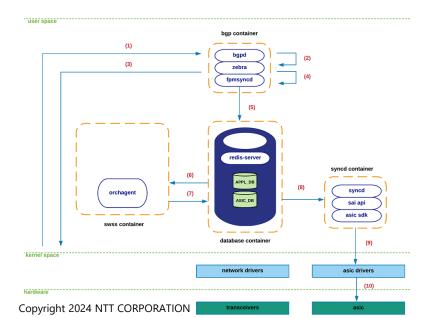
- SONiCのルーティング機能の課題
 - 旧来の経路追加メッセージのみ利用可でありNexthop Group (netlinkメッセージ)が利用できない
 - 標準ではBGPのみ利用可でありOSPF等のIGPサポートしていない



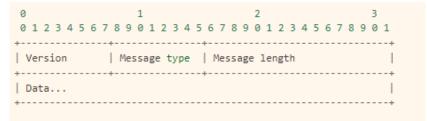
SONiCにおける経路更新の動作概要(1/2)



- 1. Linuxカーネルからbgpdプロセス(FRR)への受信BGPパケットの転送(COPP動作)
- 2. bgpdはzebraヘプレフィックスとプロトコルネクストホップを通知(FRR内部動作)
- 3. zebraがLinuxカーネルへ経路アップデート(netlinkメッセージ)通知
- 4. zebraがfpmsyncd機能へ経路アップデート(fpm形式netlinkメッセージ)通知
- 5. fpmsyncdがRedis DB(APPL_DB)を更新



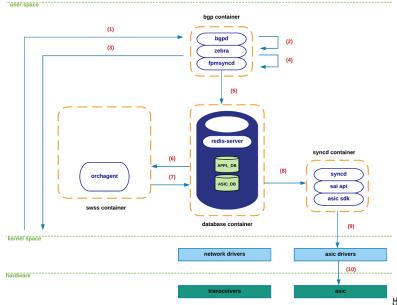
fpm形式netlinkメッセージ



SONiCにおける経路更新の動作概要(2/2) ◎



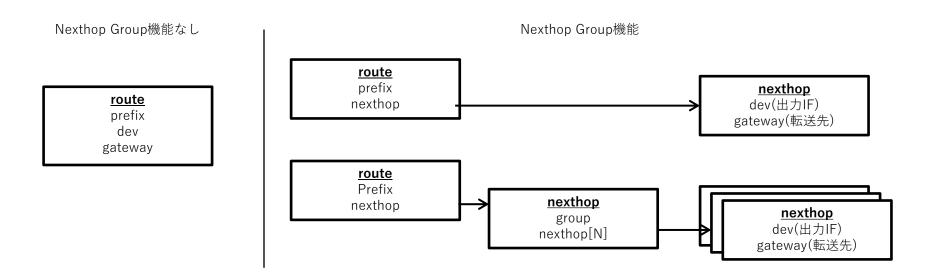
- 6. OrchagentがRedis DB(APPL_DB)の更新情報を受信
- 7. OrchagentがRedis DB(ASIC_DB)を更新
- 8. SyncdがRedis DB(ASIC_DB)の更新情報を受信
- 9. SyncdがSAI経由でASICドライバを制御
- 10. ASICドライバがハードウェアを制御



Nexthop Groupとは



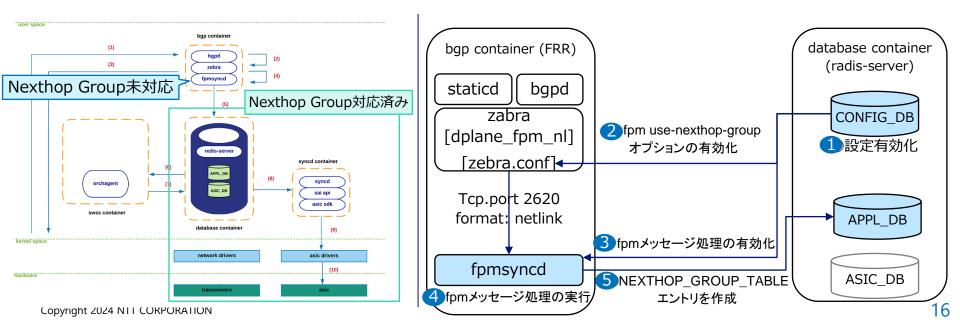
- Nexthop Groupは、nexthop情報をnexthop objectとroute objectで分離をしている。
- nexthop groupのメリットとして、「メモリ消費量の削減」、「追加・更新に必要な時間の短縮」がある。



Fpmsyncd拡張の概要

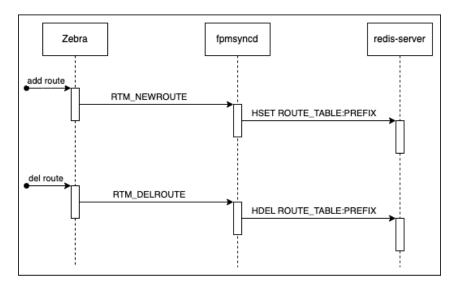


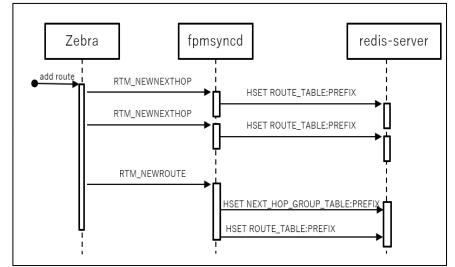
- 経路処理の効率化であるNext Hop GroupにDBからASICまでは対応している。
- FRRとAPPL_DB間のfpmsyncdはNext Hop Groupに非対応である。
- fpmsyncdをNext Hop Group対応を行い経路処理の効率化を目指す。





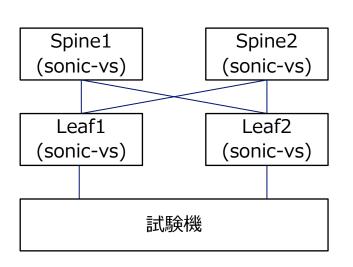
- Next Hop Groupを使用しない場合は、zebraからRTM_NEWROUTEをfpmsyncdで ROUTE_TABLEに変換してAPPL_DBに送信する。
- Next Hop Groupを使用する場合は、zebraからRTM_NEWNEXTHOPをfpmsyncdで NEXT_HOP_GROUP_TABLEとROUTE_TABLEに変換して送信する。

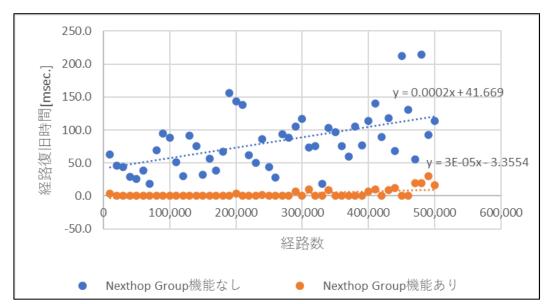






- 測定には仮想版(sonic-vs)で1万経路~50万経路までBGP経路の印加を行い切り替え時間の測定を行った。
- 測定した結果、NexthopGroup対応により性能向上が見えた。

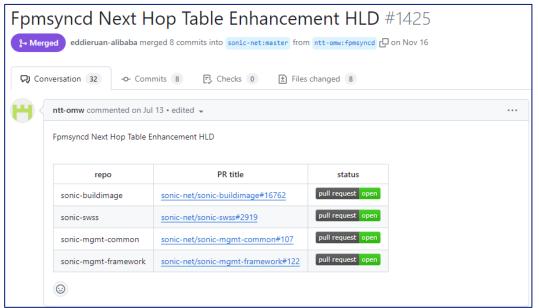




Fpmsyncd拡張のアップストリーム



- Fpmsycnd拡張のアップストリームを行っている
- HLD(High-Level Design Documents)がmasterにマージ完了
- 残りはコードPRのマージ



目次

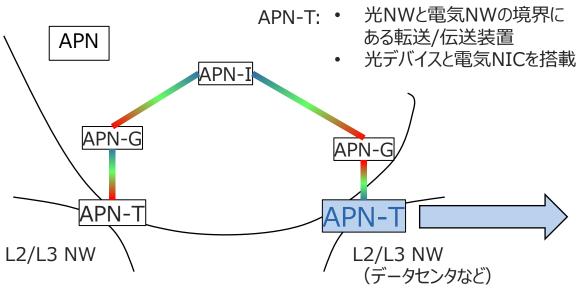


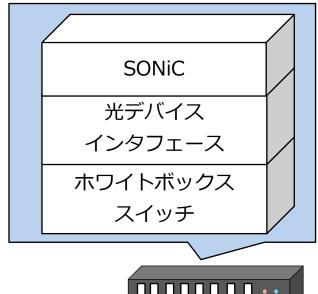
- SONICの概要
- SONICの課題
- SONiCのマネジメントプレーン(外部制御プロトコル)
- SONiCのコントロールプレーン(ECMP経路処理)
- · SONiCのデータプレーン(伝送機能サポート)

OSSによるIOWN APN-T機能の実現可能性の探求



- APN-T(All Photonic Networkの光ゲートウェイ)に資する機能の実装をOSSで実現したい
- SONiCでの光デバイス対応は確立中の段階でAPN-T機能実現までは程遠い
- APN向け伝送転送装置拡充に向けSONiCで対応する光デバイス拡充を行った





参考: IOWN Global Forum, Open All-Photonic Network Functional Architecture version2, [online] https://iowngf.org/wp-content/uploads/formidable/21/IOWN-GF-RD-Open_APN_Functional_Architecture-2.0.pdf

光伝送方式と実装確立状況



- IOWN APNで採用が検討される(*)光伝送インタフェースへのSONiC対応状況を調査した
- 長距離伝送向け伝送方式であるCFP2に対応していない
 - → SONiC向け機能モジュールを新規開発し、動作を確認した

	CFP2 (CFP-MSA) (OpenROADM)	400G-ZR	OpenZR+
転送速度	40Gb, 100G, 200G, 400G	400G	100G, 200G, 300G, 400G
変調方式 (長距離伝送に効果)	振幅変調:NRZ, PAM4 位相変調:QPSK,16/64/256QAM	位相変調: 16QAM	位相変調:QPSK, 8QAM, 16QAM
FEC (長距離伝送に効果)	フレーミングに準拠 OTU4:RS-FEC(GFEC) FOIC: CFEC	CFEC	OFEC
伝送距離	< 1000km	< 80km	< 120km
マネジメント インタフェース	MDIO	CMIS	CMIS
SONiC向けモジュール の有無	検討段階 → モジュール開発	存在(^(**) Microsoft)	存在(^(**) Microsoft)

(*) IOWN Global Forum, Open All-Photonic Network Functional Architecture, Oct. 2023, [online] https://iowngf.org/wp-content/uploads/formidable/21/IOWN-GF-RD-Open APN Functional Architecture-2.0.pdf

(**) https://github.com/sonicnet/SONiC/blob/master/doc/platform_api/CMIS_and_C-CMIS_support_for_ZR.md

選定ハードウェア(ホワイトボックススイッチ)



- APN-TならびにL2/L3スイッチ装置に求める性能要求を以下のように仮定した
 - 長距離伝送光デバイス(CFP2)対応
 - 大容量スイッチング能力
 - ベンダによるサポートの有無
- → 条件にあうEdge Core AS7716-SC (Cassini)をホワイトボックススイッチに選定した

	AS7716-SC (Cassini)	Galileo 1	Galileo flex T
長距離光伝送モジュー ル対応	O(CFP2)	O(CFP2)	O(CFP2)
スイッチング容量 (全二重)	6.4 Tbps	4 Tbps	未搭載
ベンダサポート状況	サポート継続	EOL	EOL
SONiC対応状況	X	X	X

7

SONiCを稼働させる プラットフォームとして選定

CFP2向けマネジメントインタフェース機能



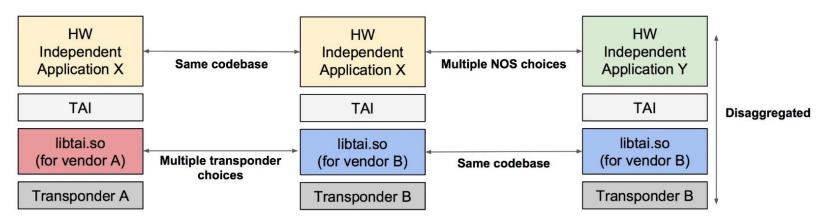
• マネジメントインタフェースとしてMDIOインタフェース操作実績のある

Transponder Abstraction Interface(TAI)を採用した

^{(***}TAI:光デバイスとシステム(OS)の間のインタフェース

MDIOを含む光デバイス向けマネジメントインタフェースをTAI APIで一括操作TAI対応ライブラリ(libtai.so)があるデバイスならTAI経由で操作可能

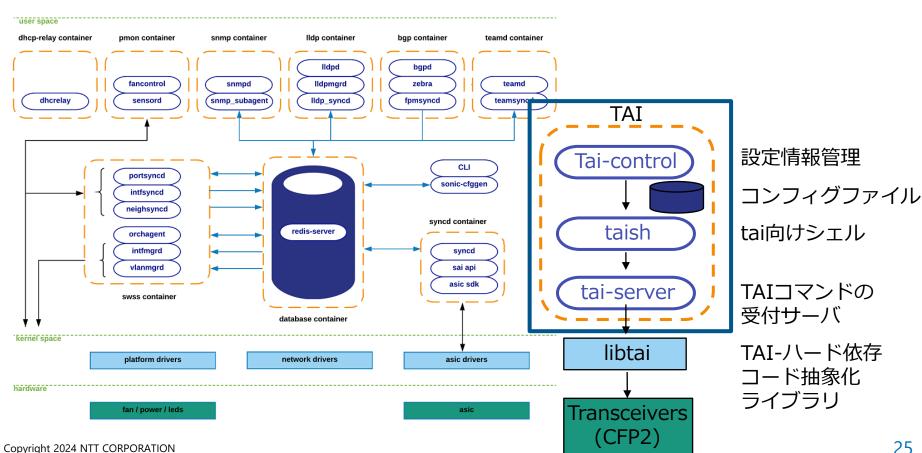
(***)TAI github https://github.com/Telecominfraproject/oopt-tai/tree/master



出典:W. Ishida,光伝送装置のオープン化動向, TIP summit 2018 出張レポート , [online] https://medium.com/nttlabs/光伝送装置のオープン化動向-tip-summit-2018-出張レポート-edf1c474c3a1

TAI実装アーキテクチャ



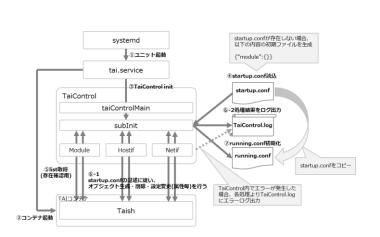


動作シーケンス



SONiC起動時: systemdが起動 → 起動用サービス(tai.service)で初期化/TAIコンテナ起動

- subInitクラスで光デバイス設定ファイルの呼び出しやデバイスの挿抜確認を実施した パラメータ設定時:taishよりコマンドを入力
- 各種設定は光デバイス設定ファイル(running.conf)に記録
- エラーチェックをsubクラス(下図ではsubHostif)で実施



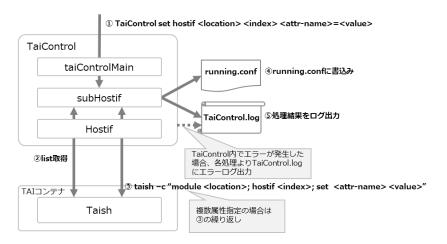
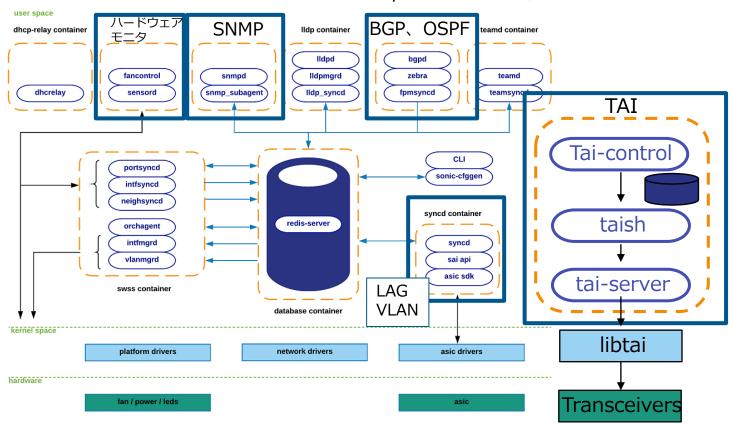


図:SONiC起動時のTAIコンテナ起動シーケンス 図:光デバイス向けパラメータ(TAIアトリビュート) 設定時

動作確認済み機能



光伝送機能との相性確認のため、主要なL2/L3機能との動作確認を行った

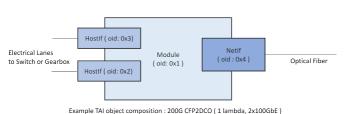


動作確認設定(TAI)



TAIが設定/参照/更新する代表的な光デバイスのパラメータは下記の通りである

	光モジュール各種情報
	ベンダ名
 モジュール本体	シリアル番号
(Module object)	ファームウェアバージョン
(i roddio object)	稼働状態
	(パラレル伝送における)電気/光レーン数
	リンクup/down情報
電気インタフェース	転送速度
(Host Interface)	FEC
	信号電力
光インタフェース (Network Interface)	転送速度
(1101110111101110011000)	変調方式



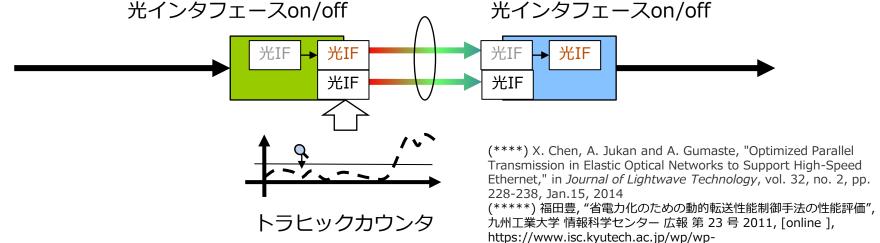
TAIにおける光デバイスのオブジェクト

出典: W. Ishida, Transponder Abstraction Interface, [online]:https://github.com/Telecominfraproject/oopt-tai/blob/master/docs/20211105_TAI.pdf

試作品を活用した光パス動的増減設機能



- 電力削減のための光パスの並列転送技術(****)と電気信号通信における 転送能力の動的変更技術(*****)が学術レベルで存在する
- 本試作品を活用して同様のコンセプトが実現できないか、機能を試作してみた
 - 本機能は試作品における下記機能を活用する。
 - トラヒックカウンタ
 - 光インタフェースon/off, L2インタフェース設定
 - LAG



content/uploads/2020/03/koho23-kaisetu4.pdf

トラヒック監視型光パス動的増減設機能



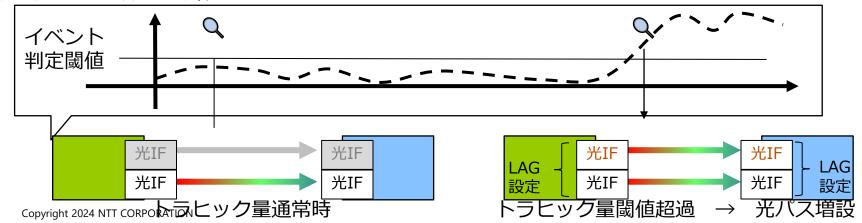
動作:トラヒック増加時に光パスを増設、減少時に減設(光トランシーバの電力削減)

流れ(例:光パス増設):1. トラヒックを監視

- 2. 監視トラヒック量が閾値を超える
- 3. 送信側/受信側に増設イベント通知
- 4. 送信側/受信側それぞれで光トランシーバ設定 + LAG設定
 - → 光パス確立

要求条件:増設イベント検知からトランシーバ設定完了までの時間を短くすること

例:光パス増設時の動作

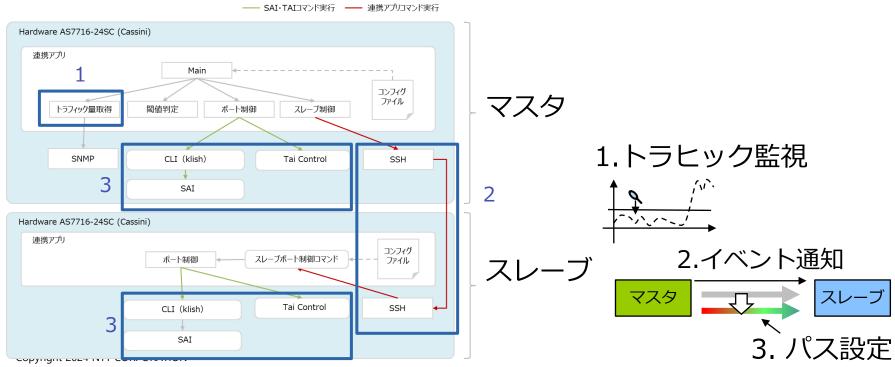


マスタ/スレーブのアーキテクチャ



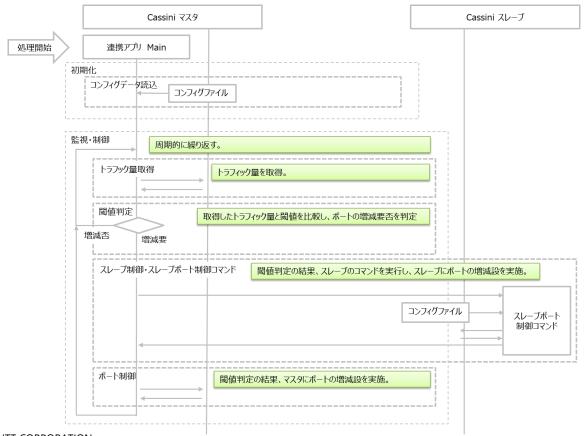
主要処理は以下の方法で実施する。

- 1. トラフィック監視: SNMP経由でポーリング
- 2. マスター →スレーブへのメッセージ: SSH経由で通知
- 3. 光インタフェース/LAG: TAI/SAIのコマンドをシェルに入力



(参考)動作シーケンス (詳細版)



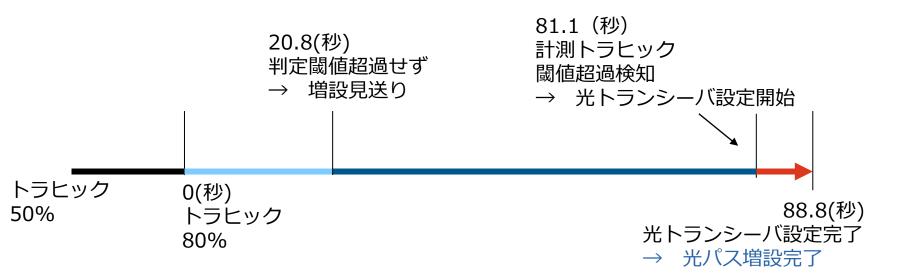


評価:光パス増設に要した時間



トラヒックを増加させてトータルで90秒ほどで光パス設定完了時間の内訳:

- ・ 閾値判定まで60-120秒(増設判定タイミングは1分周期)
- 光パス設定に7.7秒



評価:光パス動的増減設機能のCPU/メモリ負荷



当該機能の負荷はシステム全体と比べ軽微であることを確認した

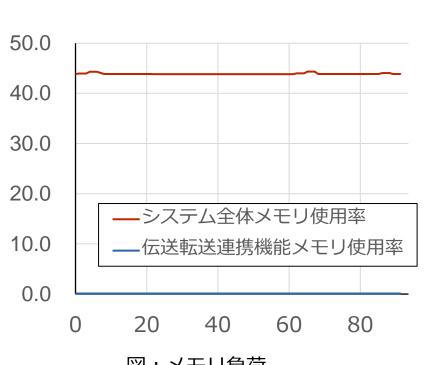
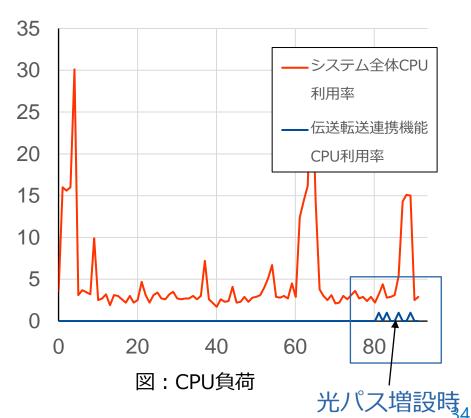


図:メモリ負荷



参考:実行可能コマンド (スイッチ,L2/3インタフェース)



No		
1		show version
2		show clock
3		show boot
4		show environment
5		show reboot-cause
		show reboot-cause
6		history
7		show uptime
8		show logging
9		show users
		show platform
10	_ , _	summary
l	スイッチ	show platform
11		syseeprom
10		show platform
12		ssdhealth
10		show platform
13		psustatus
14		show platform fan
15		show platform
15		temperature
16		show interfaces
16 17		transceiver
18		show services
18		docker ps

1		vtysh
2		config terminal
3		router bgp
4		router ospf
5		interface
6		route-map
7		address-family ipv4
8		bap router-id
8		ospf router-id
10		bgp bestpath as-path multipath-relax
11		bgp ebgp-requires-policy
12		bgp log-neighbor-changes
13		neighbor local-as
14		neighbor maximum-prefix-out
15		neighbor prefix-list
16		neighbor remote-as
17		neighbor route-map
18		
19		network [BGP]
20		network [OSPF]
21		timers bgp
		neighbor activate
22		neighbor allowas-in
23 24		maximum-path
		match ip address
25		set as-path prepend
26		set local-preference
27	L2/L3インタフェース	set metric
28	22/2017/7	ip ospf cost
29		ip ospf hello-interval
30		ip ospf passive
31		access-list
32		ip prefix-list
33		clear ip bgp
34		show ip ospf
35		show ip ospf interface
36		show ip ospf neighbor
37		show running-config ospfd
38		show bgp summary
39		show bgp neighbors
40		show bgp network
41		config interface ip
42		config interface shutdown
43		config interface startup
44		config loopback
45		config route
46		show feature status
47		show interfaces autoneg status
48		show interfaces autoney status show interfaces counters
49		show interfaces counters show interfaces status
50		show interfaces status show ip interfaces
51		
52		show ip prefix-list
52		show ip route
		show runningconfiguration bgp
54		show route-map

参考:動作確認済み光インタフェースパラメータ



(TAIア	トリ	ビュー	h)	(1/	2)
-------	----	-----	------------	-----	----

TAIオブジェクト名	設定内容	TAI アトリビュート (パラメータ名)	Read	write	delete
	TXの無効	TAI_NETWORK_INTERFACE_ATTR_TX_DIS	0	0	0
	出力光信号パワーの設定	TAI_NETWORK_INTERFACE_ATTR_OUTPUT_POWER	0	0	0
	周波数設定 (TX)	TAI_NETWORK_INTERFACE_ATTR_TX_LASER_FREQ	0	0	0
	TXレーザの微調整周波数設定(Hz)	TAI_NETWORK_INTERFACE_ATTR_TX_FINE_TUNE_LASER_FREQ	0	0	0
	変調方式の設定	TAI_NETWORK_INTERFACE_ATTR_MODULATION_FORMAT	0	0	0
	差分位相エンコーディングの設定	TAI_NETWORK_INTERFACE_ATTR_DIFFERENTIAL_ENCODING	0	0	0
	光デバイスの稼働状態	TAI_NETWORK_INTERFACE_ATTR_OPER_STATUS	0		
	パルスシェーピング(TX)の有効/無効	TAI_NETWORK_INTERFACE_ATTR_PULSE_SHAPING_TX	0	0	0
	パルスシェーピング(RX)の有効/無効	TAI_NETWORK_INTERFACE_ATTR_PULSE_SHAPING_RX	0	0	0
	パルスシェーピング(TX)ベータ値	TAI_NETWORK_INTERFACE_ATTR_PULSE_SHAPING_TX_BETA	0	0	0
	パルスシェーピング(RX)ベータ値	TAI_NETWORK_INTERFACE_ATTR_PULSE_SHAPING_RX_BETA	0	0	0
Network-IF	可変光アッテネータ(VOA)(RX)の設定	TAI_NETWORK_INTERFACE_ATTR_VOA_RX	0	0	0
	ループバックタイプの設定	TAI_NETWORK_INTERFACE_ATTR_LOOPBACK_TYPE	0	0	0
	PRBSタイプの設定	TAI_NETWORK_INTERFACE_ATTR_PRBS_TYPE	0	0	0
	チャネル1周波数の設定	TAI_NETWORK_INTERFACE_ATTR_CH1_FREQ	0	0	0
	ラインレートの設定	TAI_NETWORK_INTERFACE_ATTR_LINE_RATE	0	0	0
	Hard-decision FECの設定	TAI_NETWORK_INTERFACE_ATTR_FEC_TYPE	0	0	0
	光シグナル-フレームフォーマットのマッピング設定	TAI_NETWORK_INTERFACE_ATTR_CLIENT_SIGNAL_MAPPING_TYPE	0	0	0
	ネットワークインタフェースの汎用通知の有効/無効	TAI_NETWORK_INTERFACE_ATTR_NOTIFY	0	0	0
	ネットワークインタフェースアラーム通知	TAI_NETWORK_INTERFACE_ATTR_ALARM_NOTIFICATION	0	0	0
	現在の出力信号電力	TAI_NETWORK_INTERFACE_ATTR_CURRENT_OUTPUT_POWER	0		
	現在の入力信号電力	TAI_NETWORK_INTERFACE_ATTR_CURRENT_INPUT_POWER	0		
	Pre-FECビットエラーレート計算期間(µ秒)	TAI_NETWORK_INTERFACE_ATTR_CURRENT_BER_PERIOD	0	0	0
	Soft-definition FECの設定	TAI_HOST_INTERFACE_ATTR_FEC_TYPE	0	0	0
Host IF	ループバックタイプの設定	TAI_HOST_INTERFACE_ATTR_LOOPBACK_TYPE	0	0	0
חטאנ זר	信号速度	TAI_HOST_INTERFACE_ATTR_SIGNAL_RATE	0	0	0
	ホストインタフェースの汎用通知の有効/無効	TAI_HOST_INTERFACE_ATTR_NOTIFY	0	0	0

参考:動作確認済み光インタフェースパラメータ (TAIアトリビュート)(2/2)



TAIオブジェクト名	設定内容	TAI アトリビュート (パラメータ名)	Read	write	delete
	光デバイスのベンダ名	TAI_MODULE_ATTR_VENDOR_NAME	0		
	光デバイスのシリアル番号	TAI_MODULE_ATTR_VENDOR_SERIAL_NUMBER	0		
	光デバイスの部品番号	TAI_MODULE_ATTR_VENDOR_PART_NUMBER	0		
Module	光デバイスのファームウェアバージョン	TAI_MODULE_ATTR_FIRMWARE_VERSION	0		
Module	光デバイスの稼働状態	TAI_MODULE_ATTR_OPER_STATUS	0		
	ホストインタフェース数	TAI_MODULE_ATTR_NUM_HOST_INTERFACES	0		
	ネットワークインタフェース数	TAI_MODULE_ATTR_NUM_NETWORK_INTERFACES	0		
	管理者指定のインタフェースのリンクアップ/ダウン	TAI_MODULE_ATTR_ADMIN_STATUS	0		

まとめ



オープンネットワークOS SONiCを活用した研究開発の取り組みをしている。

現状のSONiCのマネジメント・コントロール・データプレーンの課題に対してのアプローチを検討して課題解決に取り組んでいる。

また、IOWN APNのコンセプトを実現する一例としてSONiCの拡張をしている。



Your Value Partner



Appendix



- 構成
 - DCで利用されるLeaf-Spineの構成で行う。
 - BGPで経路交換をする。
 - Leaf1のAPPL_DBとASIC_DBについて確認する。

admin@Leaf1:~\$ show ip route

B>* 1.1.1.1/32 [20/0] via 10.1.1.1, Ethernet52, weight 1, 00:00:06

B>* 1.1.1.2/32 [20/0] via 10.1.4.1, Ethernet56, weight 1, 00:00:06

C>* 1.1.1.3/32 is directly connected, Loopback0, 01w4d22h

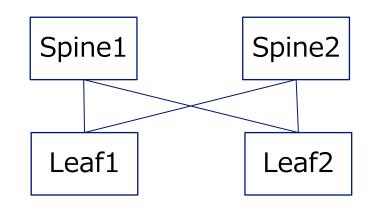
B>* 1.1.1.4/32 [20/0] via 10.1.1.1, Ethernet52, weight 1, 00:00:06

* via 10.1.4.1, Ethernet56, weight 1, 00:00:06

C>* 10.1.1.0/24 is directly connected, Ethernet52, 21:48:20

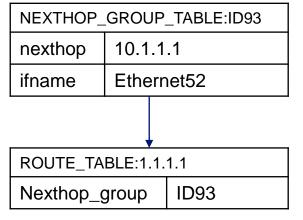
C>* 10.1.4.0/24 is directly connected, Ethernet56, 01w4d22h

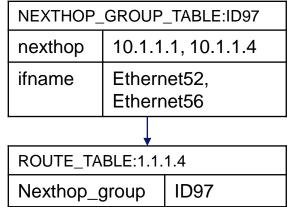
C>* 172.27.254.0/24 is directly connected, eth2, 01w4d22h

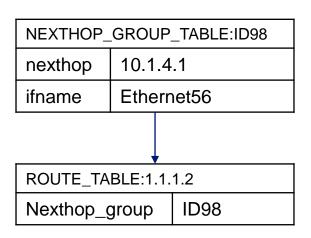




• FpmsyncdをNext Hop Group対応のAPPL_DB









FpmsyncdをNext Hop Group対応のASIC_DB

